

基于生成对抗网络的交通流参数实时估计模型

姚荣涵¹, 王荣贇¹, 张文松¹, 叶劲松^{*2}, 孙锋³

(1. 大连理工大学, 交通运输学院, 辽宁 大连 116024; 2. 交通运输部科学研究院, 综合交通运输大数据应用技术
交通运输行业重点实验室, 北京 100029; 3. 山东理工大学, 交通与车辆工程学院, 山东 淄博 255049)

摘要: 为有效调控道路网时空资源, 需实时估计交通流参数。若要准确估计交通流参数, 应详细考虑道路网交通流时空特征。本文基于生成对抗网络, 提出一种能捕捉交通流时空特征的实时估计模型, 即TSTGAN模型。该模型包括生成器和判别器两部分, 生成器利用门控卷积神经网络捕捉交通流的动态空间特征, 使用基于注意力机制的长短期记忆神经网络分析交通流的动态时间特征; 采用门控卷积神经网络与长短期记忆神经网络构建判别器; 通过对抗方式训练生成对抗网络的生成器与判别器, 实时获得交通流参数估计值。使用中国山东省淄博市12个卡口设备和美国加州洛杉矶市23个线圈检测器获得的交通流量数据, 验证TSTGAN模型的可靠性。结果表明, TSTGAN模型引入的时空模块能有效提取交通流的时空特征, 所得均方根误差和平均绝对误差比现有模型分别降低2.12%~42.41%和1.66%~40.49%, 证明所提TSTGAN模型可以提高交通流参数的估计精度。

关键词: 智能交通; 生成对抗网络; 深度学习; 交通流参数; 时空特征

Real-time Traffic Flow Parameters Estimation Model Based on Generative Adversarial Network

YAO Rong-han¹, WANG Rong-yun¹, ZHANG Wen-song¹, YE Jin-song^{*2}, SUN Feng³

(1. School of Transportation and Logistics, Dalian University of Technology, Dalian 116024, Liaoning, China;
2. Key Laboratory of Transport Industry of Big Data Application Technologies for Comprehensive Transport,
China Academy of Transportation Sciences, Beijing 100029, China; 3. School of Transportation and
Vehicle Engineering, Shandong University of Technology, Zibo 255049, Shandong, China)

Abstract: To effectively allocate the spatio-temporal resources of a road network, it is necessary to estimate the traffic flow parameters in real time. The accurate estimation of traffic flow parameters requires the detailed consideration of the spatio-temporal characteristics of traffic flow in the road network. Based on the generative adversarial network, a real-time estimation model that can capture the spatio-temporal characteristics of traffic flow was formulated, that is, the TSTGAN model. This model included a generator and a discriminator. In the generator, the gated convolutional neural network was used to capture the dynamic spatial characteristics of traffic flow, and the long short-term memory neural network based on the attention mechanism was used to analyze the dynamic temporal characteristics of traffic flow. The discriminator consisted of the gated convolutional neural network and the long short-term memory neural network. The generator and discriminator in the generative adversarial network were trained by an adversarial mode, and the real-time estimated values of traffic flow parameters were obtained. The reliability of the TSTGAN model was validated using the traffic flow data obtained from 12 bayonet devices in Zibo City, Shandong Province, China, and 23 loop detectors in Los Angeles, California, America. The results show that: the introduced spatio-temporal block in the TSTGAN model can effectively extract the spatio-temporal characteristics of traffic flow, and the obtained root mean

收稿日期: 2022-01-09

修回日期: 2022-03-13

录用日期: 2022-03-23

基金项目: 国家自然科学基金/National Natural Science Foundation of China(52172314); 交通运输部科学研究院综合交通运输大数据应用技术交通运输行业重点实验室开放课题/ Open Foundation of Key Laboratory of Transport Industry of Big Data Application Technologies for Comprehensive Transport(2020B1203)。

作者简介: 姚荣涵(1979-), 女, 山西运城人, 副教授, 博士。

***通信作者:** yejs@motcats.ac.cn

square and mean absolute errors decrease by 2.12%~42.41% and 1.66%~40.49%, respectively, compared with those obtained from the existing models, which indicates that the formulated TSTGAN model can improve the estimation precision of traffic flow parameters.

Keywords: intelligent transportation; generative adversarial network; deep learning; traffic flow parameters; spatio-temporal characteristics

0 引言

随着城市化与机动化进程加快,城市交通需求与供给矛盾日益加剧,伴随而来的交通拥堵和环境污染等问题严重影响城市可持续发展。智能交通系统借助海量出行数据及先进信息技术,将交通运行状态实时分享给道路使用者,从而提高道路时空资源利用率。交通运行状态依赖于交通流参数,其精准估计有利于交通管控策略的制定,帮助道路使用者提前规划出行路线,还能高需求区域调配更多公共资源。

众所周知,交通流数据具有明显的时空相关性^[1]。经典的历史平均模型和长短期记忆(Long Short-Term Memory, LSTM)神经网络等只能考虑交通流的时间相关性,无法考虑交通流的空间相关性,以致忽略了上下游交通运行状态之间的关联。因此,需进一步提高交通流参数估计的精度。

道路网中各路段相互连接,目标断面交通流主要受其上下游交通流影响。因此,越来越多的研究者开始考虑道路网空间相关性对交通流及其参数估计的影响。CNN模型有局部连接和权值共享的特点,ZHANG等^[2]和YAO等^[3]基于此特点利用CNN模型提取网格化道路网的交通流参数的空间特征。

道路网空间不同于一般的欧式空间,车辆移动必须途径道路,因此,道路网空间更适合表达为图结构。YU等^[4]、LIAO等^[5]及陈喜群等^[6]将道路网描述为基于距离的无向图结构,利用图卷积神经网络通过考虑道路之间的连接关系估计交通流参数,往往比卷积神经网络拥有更好的性能表现。

GOODFELLOW等^[7]提到的生成对抗网络(Generative Adversarial Network, GAN)自2014年提出后成为新的研究热点,通过生成器与判别器之间的博弈,使得生成器能够生成真实数据。GAN模型最初被应用于图像生成和视频预测等领域。目前,已有学者将GAN模型用于交通流参数估计。GUPTA等^[8]提出SocialGAN模型,基于生成对抗网络预测行人轨迹,能够生成更加符合社会规范的行人轨迹,说明GAN模型也适用于时间序列预测。

但该研究仅考虑了行人轨迹之间的时间相关性,没有考虑其空间相关性。ZHANG等^[9]在TrafficGAN模型中考虑交通流时空特征,利用历史交通流数据生成未来交通流数据,但是仅提取了交通流的静态时空特征,无法反映其动态时空特征,且只能进行单步预测。

针对以上研究存在的不足,本文利用门控卷积神经网络提取交通流的动态空间特征,使用基于注意力机制的LSTM神经网络提取交通流的动态时间特征,基于编码-解码结构进行多步预测,构建基于交通时空生成对抗网络(Traffic Spatio-Temporal Generative Adversarial Network, TSTGAN)的交通流参数估计模型。

1 TSTGAN模型

为描述道路网的交通运行状态,构建表征交通流参数变化的交通流时空矩阵。定义断面 n 在一段时间内的交通流参数为 $F_n = [x_{1,n}, x_{2,n}, x_{3,n}, \dots, x_{t,n}, \dots, x_{T,n}]$,其中, $x_{t,n}$, $t \in \{1, 2, 3, \dots, T\}$ 为时刻 t 断面 n 的交通流参数, T 为历史交通流数据的时间间隔数。将所有断面的历史交通流参数组合在一起形成交通流时空矩阵 $F = [F_1, F_2, F_3, \dots, F_n, \dots, F_N]$, $n \in \{1, 2, 3, \dots, N\}$,其中, N 为断面数。

交通流参数估计是指给定 T 个时间间隔的历史交通流参数,估计第 $T+1$ 到 $T+P$ 时间间隔内的交通流参数,其中, P 为交通流数据估计的时间间隔数。由于TSTGAN模型引入空间模块和时间模块,下面依次介绍空间模块、时间模块和TSTGAN模型的具体结构。

1.1 空间模块

道路网中,某一路段交通运行状态通常受其相邻路段影响,也会被非相邻路段影响。交通流在空间上表现出的这种相互依赖称为交通流的空间特征。由于距离远近的差异,相邻路段上的交通流数据往往高度相关。

车辆在道路上行驶不仅受路段长度和道路宽度等静态固有属性影响,而且受信号控制和交通事件等动态不可控因素影响。因此,空间特征有静态

与动态之分。静态空间特征是指由于长度和宽度等静态因素,不同断面交通流数据之间存在潜在的相关性;动态空间特征是指由于拥堵和事故等动态因素,随之改变的交通状况使得不同断面交通流数据之间的相关性发生改变。

淄博市12个交通流量观测断面所处位置及其编号如图1所示。



图1 观测断面位置及编号

Fig. 1 Locations and numbering of observation sections

这些观测断面均位于主干道上相应交叉口的进口道上。以5 min为时间间隔,统计每个观测断面的交通流量序列。描述这些观测断面在所有时段内两两之间交通流量的皮尔森相关系数矩阵如图2所示。




图2 观测断面交通流量相关系数矩阵

Fig. 2 Correlation coefficient matrix of traffic volumes obtained from observation sections

由此可见,不同观测断面采集到的交通流量数据具有空间相关性,说明交通流数据具有空间特征。

不同观测断面的交通流量数据不仅整体上具

有空间相关性(即静态空间特征),而且这种空间相关性随着时间推移而发生变化(即动态空间特征)。7:00-9:00、12:00-14:00和17:00-19:00这3个高峰时段内不同观测断面交通流量的皮尔森相关系数矩阵如图3所示。

由图3可知,不同时段内,各观测断面之间的相关系数表现出明显差异,说明交通状况变化的确影响不同断面交通流数据之间的相关性,也证明确实存在动态空间特征。因此,需要同时提取交通流数据的静态空间特征和动态空间特征。

现有研究常利用卷积层提取相邻断面之间的空间特征,但直接利用卷积层提取的是其静态特征,鲜有研究提取其动态特征。

为提取交通流的静态空间特征,将交通流时空矩阵作为初始特征输入卷积层,卷积核在输入特征图上滑动遍历,并进行卷积运算,卷积核大小为 1×3 ,卷积核卷积操作可表达为

$$f_{t,n} = w_1^{(k)} \cdot x_{t,n} + w_2^{(k)} \cdot x_{t,n+1} + w_3^{(k)} \cdot x_{t,n+2} \quad (1)$$

式中: $f_{t,n}$ 为时刻 t 断面 n 交通流参数的输出值; $w_1^{(k)}$ 、 $w_2^{(k)}$ 和 $w_3^{(k)}$ 分别为卷积核第 k 层卷积层第1,2,3个权重; $x_{t,n+1}$ 和 $x_{t,n+2}$ 分别为时刻 t 断面 $n+1$ 和 $n+2$ 交通流参数的输入值。

当卷积核遍历输入特征图,即可获得交通流参数空间特征的初步表达,即

$$\mathbf{F}^{(k)} = \begin{bmatrix} f_{1,1}^{(k)} & f_{1,2}^{(k)} & f_{1,3}^{(k)} & \cdots & f_{1,m}^{(k)} \\ f_{2,1}^{(k)} & f_{2,2}^{(k)} & f_{2,3}^{(k)} & \cdots & f_{2,m}^{(k)} \\ f_{3,1}^{(k)} & f_{3,2}^{(k)} & f_{3,3}^{(k)} & \cdots & f_{3,m}^{(k)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f_{t,1}^{(k)} & f_{t,2}^{(k)} & f_{t,3}^{(k)} & \cdots & f_{t,m}^{(k)} \end{bmatrix} \quad (2)$$

式中: $m = n - 2(k - 1)$ 。

卷积神经网络如图4所示。设置多个卷积核,可使卷积层提取交通流数据在空间维度上的不同特征,每个卷积核经过卷积操作都会形成一张特征图。同时,为提取不相邻断面之间的空间特征,需要增加卷积层的深度,以便确保提取更加全面的空间特征。

给定初始交通流时空矩阵 $\mathbf{F}^{(0)}$,经过 k 层卷积层,提取的静态空间特征为 $\mathbf{F}_{ST}^{(k)}$,即

$$\mathbf{F}_{ST}^{(k)} = \text{ReLU}(\mathbf{W}_{ST}^{(k)} \otimes \mathbf{F}_{ST}^{(k-1)} + \mathbf{b}_{ST}^{(k)}) \quad (3)$$

式中: $\mathbf{F}_{ST}^{(k-1)}$ 为经过 $k-1$ 层卷积后提取的表示静态空间特征的张量,当 $k=1$ 时, $\mathbf{F}_{ST}^{(k-1)} = \mathbf{F}^{(0)}$,即上述交通流时空矩阵 \mathbf{F} ; $\mathbf{W}_{ST}^{(k)}$ 、 $\mathbf{b}_{ST}^{(k)}$ 分别为提取静态空间特征时第 k 层卷积层中卷积核的权重、偏置;ReLU为

线性整流函数;⊗为卷积操作。


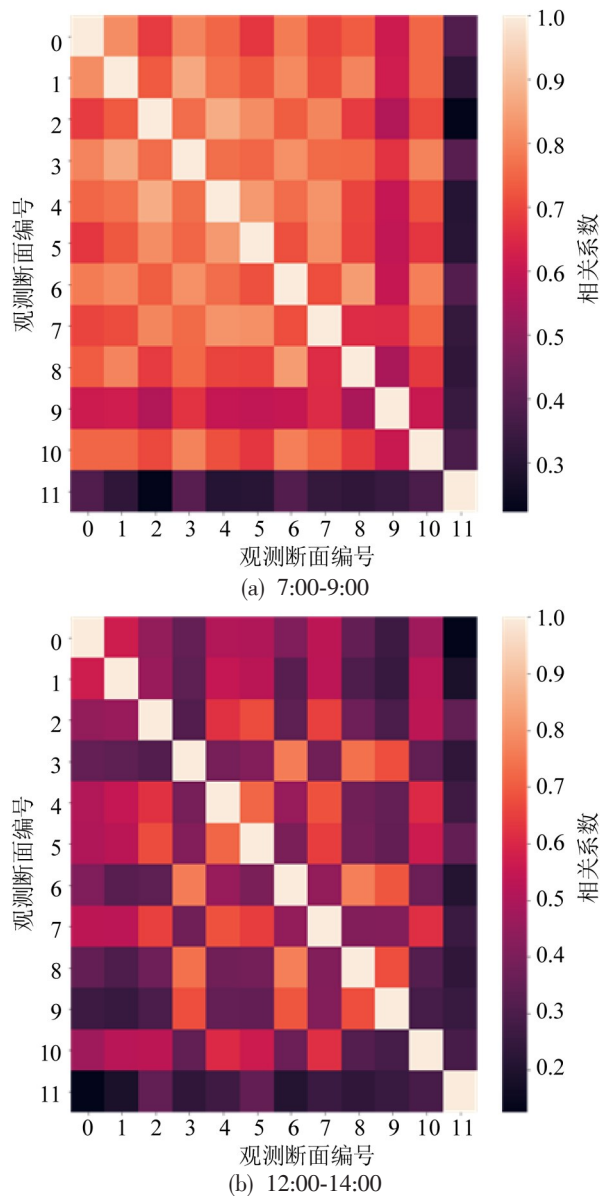


图3 不同高峰时段内观测断面交通流量相关系数矩阵
Fig. 3 Correlation coefficient matrices of traffic volumes obtained from observation sections during different peak periods

为提取交通流的动态空间特征,引入门控机制^[5]学习不同时刻不同区域的交通流特征。门控机制中增加 Sigmoid 激活函数,将输入信息映射到[0, 1]区间,从而控制信息流出,重点聚焦关键区域对交通流未来发展趋势的影响,保证提取不同交通状况下交通流的空间特征。Sigmoid 激活函数为

$$\sigma(x)=\frac{1}{1+\exp(-x)} \tag{4}$$

式中: $\sigma(x)$ 为自变量为 x 的 Sigmoid 激活函数。




图4 卷积神经网络结构
Fig. 4 Structure of convolutional neural network

加入门控机制后,提取的动态空间特征张量为 $F_{DY}^{(k)}$,即

$$F_{DY}^{(k)} = (W_{DY}^{(k)} \otimes F_{DY}^{(k-1)} + b_{DY}^{(k)}) \odot \sigma(W_G^{(k)} \otimes F_{DY}^{(k-1)} + b_G^{(k)}) \quad (5)$$

式中: $F_{DY}^{(k-1)}$ 为经过 $k-1$ 层门控卷积后提取的表示动态空间特征的张量,当 $k=1$ 时, $F_{DY}^{(k-1)} = F^{(0)}$; $W_{DY}^{(k)}$ 、 $b_{DY}^{(k)}$ 分别为提取动态空间特征时第 k 层卷积层的权重、偏置; $W_G^{(k)}$ 、 $b_G^{(k)}$ 分别为第 k 层门控单元的权重、偏置; \odot 为哈达玛积。

引入门控机制搭建的空间模块如图5所示。最终提取的空间特征 F_{SP} 为静态空间特征 F_{ST} 与动态空间特征 F_{DY} 之和,即

$$F_{SP} = \text{ReLU}(F_{ST} + F_{DY}) \quad (6)$$




图5 空间模块
Fig. 5 Spatial block

1.2 时间模块

一个断面的交通流数据通常为时间序列数据,其中,某个时段的数据往往依赖于该时段之前几个时段的数据。交通流在时间上表现出的这种相互依赖称为交通流的时间特征。

LSTM神经网络增加门结构控制和保护网络状态,解决了传统循环神经网络存在的梯度弥散问题,且缓解了梯度爆炸问题,所以,选择LSTM神经网络捕捉交通流数据的时间特征,将空间模块的输出在空间维度上铺平后的结果 $F_{SP} = [F_{SP,1}, F_{SP,2}, F_{SP,3}, \dots, F_{SP,t}, \dots, F_{SP,T}]$ 作为LSTM神经网络的输入。LSTM神经网络包括遗忘门、输入门和输出门,遗忘门将之前的隐藏信息选择性遗忘,输入门将新的信息选择性地输入网络,输出门决定输出信息。遗忘门、输入门和输出门的表达式为

$$f_t = \sigma(W_F \cdot [h_{t-1}, F_{SP,t}] + b_F) \quad (7)$$

$$i_t = \sigma(W_I \cdot [h_{t-1}, F_{SP,t}] + b_I) \quad (8)$$

$$o_t = \sigma(W_O \cdot [h_{t-1}, F_{SP,t}] + b_O) \quad (9)$$

式中: f_t 、 i_t 和 o_t 分别为第 t 个遗忘门、输入门和输出门的输出向量; W_F 、 W_I 和 W_O 分别为遗忘门、输入门和输出门的权重; b_F 、 b_I 和 b_O 分别为遗忘门、输入门和输出门的偏置; h_{t-1} 为第 $t-1$ 个LSTM单元的隐藏状态向量。

输入门与备选向量 \tilde{C}_t 的乘积决定LSTM单元增加的信息,结合遗忘门对第 $t-1$ 个LSTM单元的影响,得到第 t 个LSTM单元的状态向量 C_t 。 \tilde{C}_t 与 C_t 的表达式为

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, F_{SP,t}] + b_C) \quad (10)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (11)$$

式中: W_C 、 b_C 分别为备选向量的权重、偏置; \tanh 为双曲正切函数。

最后,将状态向量 C_t 经过激活函数处理,再结合输出门的输出 o_t ,得到第 t 个LSTM单元的隐藏状态向量 h_t ,即

$$h_t = o_t \odot \tanh(C_t) \quad (12)$$

LSTM神经网络第 t 个LSTM单元的隐藏状态很难表达全部的信息,使得估计误差会随着估计步长的增加而变大,因此,多步估计的效果较差。TSTGAN模型的编码-解码结构如图6所示。

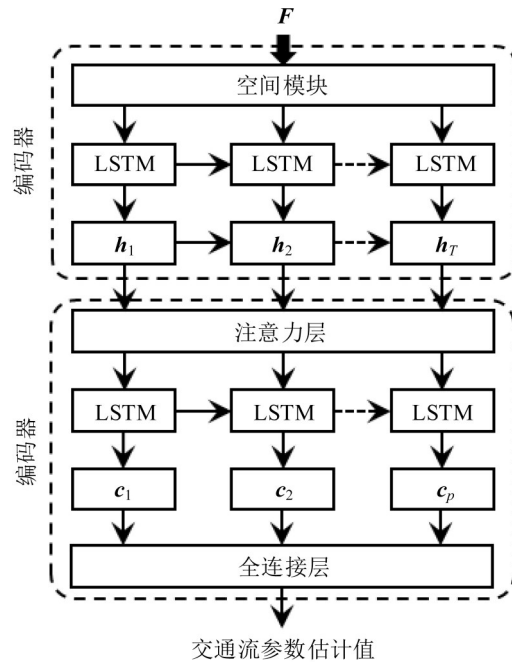


图6 编码-解码结构

Fig. 6 Structure of encoder-decoder

图6中,基于空间模块与LSTM神经网络构建

编码器;使用LSTM神经网络构建解码器;将交通网络时空编码信息全部输入解码器。这样,可以有效解决多步估计误差较大的问题。

为更准确地利用编码器每一步的隐藏状态信息,在解码器中加入注意力机制,捕捉交通流数据在时间上的动态变化。交通流参数往往不是线性变化的,不同历史间隔的交通流参数对交通运行状态的影响不同,而注意力机制可很好地提取这种时间特征。注意力描述每个历史时间间隔所得输出对估计交通流数据的贡献程度,通过计算编码器的隐藏状态 \mathbf{h} 与解码器的隐藏状态 \mathbf{H} 之间的相似性,从而确定历史交通运行状态对未来交通运行状态的影响。隐藏状态 \mathbf{h} 与 \mathbf{H} 的相似性分数 $s_{pt}(\mathbf{H}_{p-1}, \mathbf{h}_t)$ $p \in \{1, 2, 3, \dots, P\}, t \in \{1, 2, 3, \dots, T\}$ 为

$$s_{pt}(\mathbf{H}_{p-1}, \mathbf{h}_t) = \mathbf{H}_{p-1} \cdot \mathbf{h}_t \quad (13)$$

式中: \mathbf{H}_{p-1} 为解码器第 $p-1$ 个输出序列的隐藏状态; \mathbf{h}_t 为编码器第 t 个输出序列的隐藏状态。

再将所得相似性分数输入到 Softmax 函数中为编码器的每个时间步的隐藏状态分配权重,即

$$\alpha_{pt} = \frac{\exp(s_{pt})}{\sum_t \exp(s_{pt})} \quad (14)$$

式中: α_{pt} 为 \mathbf{h}_t 对第 p 步估计结果的权重。

解码器输出的上下文向量 \mathbf{c}_p 为编码器所有时间步的加权和,即

$$\mathbf{c}_p = \sum_t \alpha_{pt} \mathbf{h}_t \quad (15)$$

最后,将上下文向量 \mathbf{c}_p 经过一层全连接层得到交通流参数估计值,即

$$\hat{\mathbf{y}}_p = \mathbf{W}_{\text{FC}} \cdot \mathbf{c}_p + \mathbf{b}_{\text{FC}} \quad (16)$$

式中: $\hat{\mathbf{y}}_p$ 为第 p 步交通流参数估计值; \mathbf{W}_{FC} 和 \mathbf{b}_{FC} 分别为全连接层的权重与偏置。

1.3 TSTGAN模型

TSTGAN模型进行交通流参数实时估计的主要思想是将历史交通流时空矩阵输入编码器中生成描述交通运行状态的潜码,再经过解码器生成未来交通流时空矩阵。

编码器与解码器组成生成器,其中,编码器包括空间模块和时间模块。首先,将历史交通流时空矩阵 $\mathbf{F}^{(0)}$ 输入编码器,通过空间模块学习交通流数据的空间特征并在空间维度上铺平得到输出 $\mathbf{F}_{\text{SP}} = [\mathbf{F}_{\text{SP},1}, \mathbf{F}_{\text{SP},2}, \mathbf{F}_{\text{SP},3}, \dots, \mathbf{F}_{\text{SP},t}, \dots, \mathbf{F}_{\text{SP},T}]$ 。然后,将 \mathbf{F}_{SP} 输入时间模块,学习交通流数据的时间特征得到输

出 \mathbf{h}_t 。最后,利用基于注意力机制的编码-解码结构对交通流参数进行多步估计,得到最终的交通流参数估计值 $\hat{\mathbf{y}}_p$ 。

空间模块、LSTM层和全连接层组成判别器。先将历史交通流数据 $\mathbf{F}^{(0)}$ 分别与真实的未来交通流数据 \mathbf{y}_p 和生成的未来交通流数据 $\hat{\mathbf{y}}_p$ 结合,得到输入数据 $\mathbf{D}_T = [\mathbf{F}^{(0)}, \mathbf{y}_p]$ 和 $\mathbf{D}_F = [\mathbf{F}^{(0)}, \hat{\mathbf{y}}_p]$,分别输入空间模块,再将学习的空间特征输入LSTM层,最后经全连接层后得到交通流输出数据 \mathbf{Y}_T 和 \mathbf{Y}_F 。

TSTGAN模型通过判别器判断生成器生成的训练样本的真假,进一步通过生成器与判别器之间的对抗更新模型参数,使得生成器生成更加真实的样本。GAN模型的目标函数为

$$\min_G \max_D V(D, G) = E_{x \sim p_F(x)} [\ln D(x)] + E_{x \sim p_H(x)} \{\ln [1 - D(G(x))]\} \quad (17)$$

式中: $V(D, G)$ 为GAN模型的值函数; G 为生成器; D 为判别器; x 为交通流参数; $p_F(x)$ 为未来交通流参数分布; $p_H(x)$ 为历史交通流参数分布; $E(\cdot)$ 为变量的数学期望。

TSTGAN模型框架如图7所示。图中,生成器根据历史交通流数据学习交通流数据的概率分布,并生成未来的交通流参数估计值;判别器用来区分真实数据分布的样本 \mathbf{D}_T 与生成数据分布的样本 \mathbf{D}_F 。给定真实数据分布的样本标签为1,生成数据分布的样本标签为0。训练TSTGAN模型时,首先,固定生成器,判别器的优化目标是最大化 $E_{x \sim p_F(x)} [\ln D(x)] + E_{x \sim p_H(x)} \{\ln [1 - D(G(x))]\}$,因此, \mathbf{D}_T 输入判别器的结果接近1(即使 $D(\mathbf{D}_T)$ 结果接近1),而 \mathbf{D}_F 输入判别器的结果接近0(即使 $D[G(\mathbf{D}_T)]$ 结果接近0);然后,固定判别器,生成器的优化目标是最小化 $E_{x \sim p_H(x)} \{\ln [1 - D(G(x))]\}$,此时,生成器使 $D[G(\mathbf{D}_T)]$ 接近1。交替训练生成器与判别器,当 $p_F(x) = p_H(x)$ 时,训练结果达到全局最优。

在GAN模型的损失函数中增加L2损失函数,能提升交通流参数估计的精度^[10]。L2损失函数用来衡量交通流参数的真实值与估计值之间的差异,两者差异越大,损失函数也越大。本文使用的损失函数 L_T 为GAN模型损失函数 L_G 与L2损失函数 L_M 之和,即

$$L_T = L_G + L_M \quad (18)$$

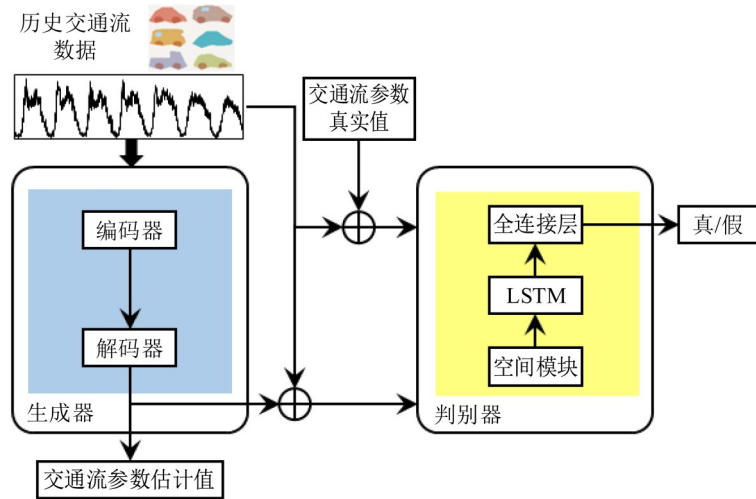


图7 TSTGAN模型框架

Fig. 7 Framework of TSTGAN model

2 案例分析

为验证 TSTGAN 模型的有效性,使用两个真实交通流量数据集估计交通流参数。第1个数据集为中国山东省淄博市相邻12个交通卡口2019年4月24日~5月7日2周的过车数据。对这些原始数据进行预处理,将其整理成时间间隔为5 min的交通流量数据,共计48384条记录。第2个数据集为美国加州洛杉矶市西切斯特街区23个线圈检测器2014年5月1日~6月30日2个月的交通流量数据,时间间隔为5 min,共计404064条记录。将这两个数据集进一步处理为交通流量时空矩阵数据,其中,80%用于模型训练,10%用于模型验证,10%用于模型测试。

2.1 性能指标

均方根误差 RMSE(单位为 $\text{veh} \cdot (5 \text{ min})^{-1}$)可以评价真实数据与所用模型的适应性,平均绝对误差 MAE(单位为 $\text{veh} \cdot (5 \text{ min})^{-1}$)能够很好地反映估计值与真实值之间的误差^[11]。RMSE 与 MAE 的值越小,说明模型精度越高,从而说明所用模型较好地提取了交通流数据的时空特征。因此,评价模型性能时,选取 RMSE 与 MAE 为评价指标,其计算式分别为

$$E_{\text{RMSE}} = \sqrt{\frac{1}{I} \sum_i (\hat{y}_i - y_i)^2}, i \in \{1, 2, 3, \dots, I\} \quad (19)$$

$$E_{\text{MAE}} = \frac{1}{I} \sum_i |\hat{y}_i - y_i|, i \in \{1, 2, 3, \dots, I\} \quad (20)$$

式中: \hat{y}_i 为交通流参数的第 i 个估计值; y_i 为交通流参数的第 i 个真实值; I 为估计值的个数。

选择历史平均模型(History Average, HA)、支持向量回归模型(Support Vector Regression, SVR)、

LSTM、卷积长短期记忆神经网络(Convolution LSTM, ConvLSTM)及时空图卷积神经网络(Spatio-Temporal Graph Convolution Network, STGCN)等现有模型,通过对比说明 TSTGAN 模型的性能。

HA 使用过去同一时刻交通流数据的平均值作为交通流参数估计值。SVR 将历史交通流数据映射到高维空间,利用线性函数拟合未来交通流数据。LSTM 常用于解决各种时间序列问题。ConvLSTM^[4] 常被用来解决时空序列问题。STGCN^[6] 利用图卷积对道路网进行建模。

所建模型采用批量训练,训练批量大小设为64,生成器和判别器的学习率均设为 2×10^{-4} ,并使用 Adam 算法。为保证实验结果的公正,上述所有模型涉及的 LSTM 单元的隐藏状态维度均设为128,选取的现有深度学习模型的训练批量大小均设为64,学习率设为 1×10^{-3} ,且均采用 Adam 优化算法训练模型。为减少随机性带来的影响,选取5次估计结果的平均值作为最终估计值。

2.2 结果分析

2.2.1 动态时空模块分析

为验证时空模块和生成对抗网络框架的作用,使用淄博市数据集。

选择以下4个模型进行对比:LSTM为基准模型,仅捕捉交通流参数的时间特征;TSTGAN_No_Adver为TSTGAN模型的生成器部分,训练时不使用对抗方式;TSTGAN_No_L2为相比TSTGAN模型,损失函数中缺少L2损失函数;TSTGAN为本文提出的模型。4个模型所得的RMSE值和MAE值如图8所示。

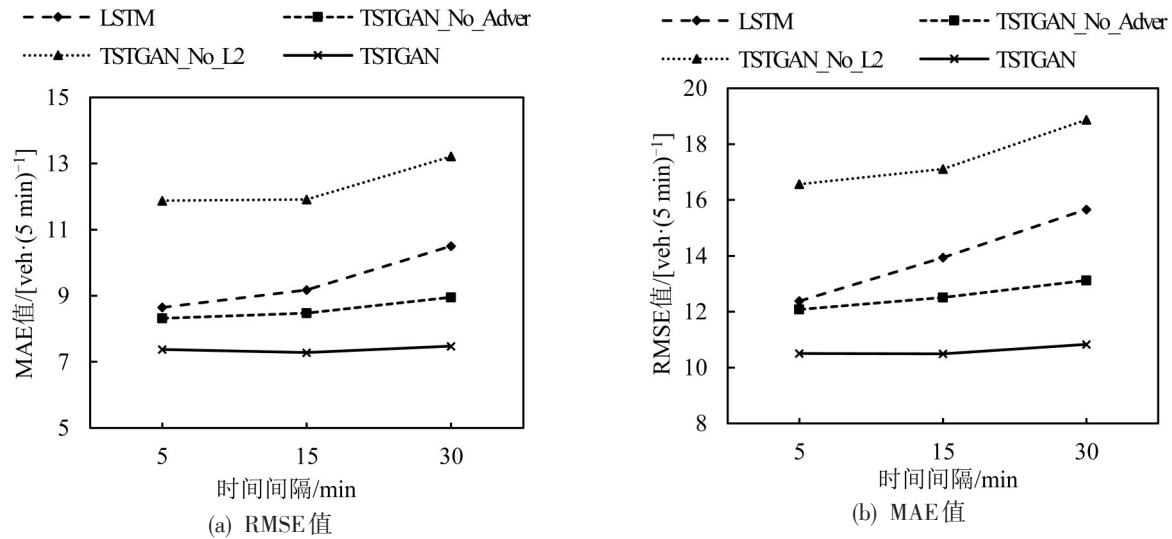


图8 各模型RMSE和MAE值
Fig. 8 RMSE and MAE values obtained from each model

相比 LSTM 神经网络,加入了时空模块的 TSTGAN_No_Adver 和 TSTGAN 模型的误差均降低。随着时间间隔增加, TSTGAN_No_Adver 和 TSTGAN 模型的 RMSE 值与 MAE 值的增加幅度都比 LSTM 神经网络小。说明交通流量数据在时空上存在相关性,且 TSTGAN 模型的时空模块能很好地提取交通流数据的时空特征。

对比 TSTGAN_No_Adver、TSTGAN_No_L2 和 TSTGAN 这 3 种模型, TSTGAN 模型精度最高。

表明结合 L2 损失函数与对抗方式共同训练生成器,其预测误差比单一使用对抗方式或者 L2 损失函数都要低,进一步说明 TSTGAN 模型估计结果更加准确。

2.2.2 淄博市数据集实验

使用淄博市数据集,随着时间推移,不断输入历史交通流量数据,在应用中即可实时估计未来交通流量。比较 TSTGAN 模型及其对比模型,各模型对未来 5, 15, 30 min 交通流参数的估计性能如表 1 所示。

表 1 淄博市数据集得到的各模型性能指标
Table 1 Performance indices of each model obtained from Zibo dataset

模型	$E_{RMSE} / [\text{veh} \cdot (5 \text{ min})^{-1}]$			$E_{MAE} / [\text{veh} \cdot (5 \text{ min})^{-1}]$		
	5 min	15 min	30 min	5 min	15 min	30 min
HA	17.0575	17.0575	17.0575	10.9997	10.9997	10.9997
SVR	12.0476	14.4172	18.8043	8.4637	9.9440	12.5628
LSTM	12.3792	13.9420	15.6634	8.6468	9.1736	10.5024
ConvLSTM	10.8953	11.1330	11.6319	7.5030	7.6077	7.8416
STGCN	11.0971	11.5875	12.4282	7.6050	7.9448	8.4994
TSTGAN	10.5048	10.4910	10.8300	7.3787	7.2817	7.4765

表 1 结果表明:相比现有模型, TSTGAN 模型所得 RMSE 值分别降低 3.58%~38.42%, 5.76%~38.50%和 6.89%~42.41%; MAE 值分别降低 1.66%~32.92%, 4.28%~33.80%和 4.65%~40.49%;随着估计步数增加,所有模型的估计精度都有所下降,但 TSTGAN 模型所受影响最小,估计性能下降最慢,从而得到最优的多步估计结果。总之,相比现有模型, TSTGAN 模型估计道路网交通流量时,尤其是多步估计时有最佳的估计性能。

2.2.3 洛杉矶市数据集实验

为验证模型的稳定性,再利用洛杉矶市数据集估计交通流参数。保持超参数不变,分别探究这些模型在工作日与周末交通流参数估计方面的性能,如表 2 和表 3 所示。

无论工作日还是周末, TSTGAN 模型的 RMSE 值与 MAE 值均小于现有模型。针对工作日, TSTGAN 模型比现有模型的 RMSE 值和 MAE 值分别降低 12.04%~38.25%和 10.56%~39.00%。针对周

末, TSTGAN 模型比现有模型的 RMSE 值和 MAE 值分别降低 2.12%~32.31% 和 2.27%~38.67%。相比

周末, 工作日数据量大, 此时, TSTGAN 模型的估计精度更高。

表 2 工作日洛杉矶市数据集得到的各模型性能指标

Table 2 Performance indices of each model obtained from Los Angeles dataset on weekdays

模型	$E_{RMSE} / [veh \cdot (5 min)^{-1}]$			$E_{MAE} / [veh \cdot (5 min)^{-1}]$		
	5 min	15 min	30 min	5 min	15 min	30 min
HA	40.9858	40.9858	40.9858	29.8282	29.8282	29.8282
SVR	34.4775	38.7388	42.5973	23.8406	26.9474	30.1627
LSTM	35.8770	35.6100	36.6831	25.4828	25.9014	26.7152
ConvLSTM	31.1134	33.3287	35.5611	22.2550	23.9506	25.4715
STGCN	30.1808	33.3052	36.0928	21.3412	23.5572	25.3683
TSTGAN	25.3101	29.1307	31.2781	18.1947	21.0176	22.6905

表 3 周末洛杉矶市数据集得到的各模型性能指标

Table 3 Performance indices of each model obtained from Los Angeles dataset on weekends

模型	$E_{RMSE} / [veh \cdot (5 min)^{-1}]$			$E_{MAE} / [veh \cdot (5 min)^{-1}]$		
	5 min	15 min	30 min	5 min	15 min	30 min
HA	39.7024	39.7024	39.7024	31.4237	31.4237	31.4237
SVR	31.3579	34.8492	38.2376	22.6234	25.5659	28.5588
LSTM	31.4327	34.2223	35.3713	21.9777	24.4231	25.3959
ConvLSTM	33.4990	34.8542	36.1430	24.0897	24.9836	25.9218
STGCN	29.4348	32.0809	35.0395	21.6691	23.2551	25.4763
TSTGAN	26.8761	30.7718	34.2974	19.2724	22.1052	24.8201

尽管洛杉矶市数据集比淄博市数据集涉及的道路断面多, 但是, TSTGAN 模型仍然能很好地提取交通流参数的时空特征, 对于 5, 15, 30 min 的时间间隔, 该模型均取得最优的估计性能。表明 TSTGAN 模型估计道路网交通流量时具有较强的普适性。

实际应用中, 交通流参数估计所需用时主要受数据读取速度和涉及的断面数影响, 断面数本质上是数据量。本文聚焦 TSTGAN 模型构建及性能测试, 不涉及数据读取速度。使用淄博市和洛杉矶市数据集测试模型性能时, 估计交通流量的用时分别为 169 ms, 219 ms, 后者涉及的断面比前者多接近 1 倍, 但用时仅增加 50 ms, 可见断面数对参数估计用时的影响不大。工程应用中, 利用 TSTGAN 模型估计交通流参数时, 配备高性能服务器, 采取分布式计算, 交通流参数实时估计完全可行。

3 结论

为深入挖掘交通流参数的动态时空特征, 基于生成对抗网络构建交通流参数实时估计模型, 即 TSTGAN 模型。本研究主要结论如下:

(1) TSTGAN 模型引入时空模块可使 RMSE 值与 MAE 值分别降低 15.14% 和 14.67% 以上; TSTGAN 模型利用生成对抗网络训练模型可使 RMSE 值与 MAE 值分别降低 13.03% 和 11.28% 以

上; 说明 TSTGAN 模型能有效提取交通流参数的动态时空特征。

(2) 与现有模型相比, 估计未来 5, 15, 30 min 交通流量, TSTGAN 模型所得 RMSE 值和 MAE 值分别降低 2.12%~42.41% 和 1.66%~40.49%。

(3) 对于交通流参数估计, TSTGAN 模型不仅适用于城市道路场景, 同时适用于高速公路场景; 当道路断面增多时, TSTGAN 模型依然表现出优异的估计性能, 说明该模型可以很好地挖掘交通流数据的动态时空特征。

参考文献

- [1] YE J X, ZHAO J J, YE K J, et al. How to build a graph-based deep learning architecture in traffic domain: A survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2020: 1-21.
- [2] ZHANG J, YU Z, QI D. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]. San Francisco: 31st AAAI Conference on Artificial Intelligence, 2017.
- [3] YAO H X, TANG X F, WEI H, et al. Revisiting spatial-temporal similarity: A deep learning framework for traffic prediction [C]. Honolulu: 33rd AAAI Conference on Artificial Intelligence, 2018.
- [4] YU B, YIN H T, ZHU Z X. Spatio-temporal graph convolutional networks: A deep learning framework for

- traffic forecasting[C]. Stockholm: Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, 2018.
- [5] LIAO B, ZHANG J, WU C, et al. Deep sequence learning with auxiliary information for traffic prediction[C]. London: KDD' 18: Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2018.
- [6] 陈喜群, 周凌霄, 曹震. 基于图卷积网络的路网短时交通流预测研究[J]. 交通运输系统工程与信息, 2020, 20(4): 49–55. [CHEN X Q, ZHOU L X, CAO Z. Short-term network-wide traffic prediction based on graph convolutional network[J]. Journal of Transportation Systems Engineering and Information Technology, 2020, 20(4): 49–55.]
- [7] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]. Montreal Advances in Neural Information Processing Systems, Curran Associates, 2014.
- [8] GUPTA A, JOHNSON J, LI F F, et al. Social GAN: Socially acceptable trajectories with generative adversarial networks[C]. Salt Lake City: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018.
- [9] ZHANG Y X, WANG S Z, CHEN B, et al. TrafficGAN: Network-scale deep traffic prediction with generative adversarial nets[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(1): 219–230.
- [10] 代亮, 梅洋, 钱超, 等. 基于生成对抗网络的大规模路网交通流预测算法[J/OL]. 控制与决策, 2021: 1–9. <https://doi.org/10.13195/j.kzyjc.2020.0333>. [DAI L, MEI Y, QIAN C, et al. Traffic flow forecasting algorithm for large-scale road network based on GAN [J/OL]. Control and Decision, 2021: 1–9. <https://doi.org/10.13195/j.kzyjc.2020.0333>.]
- [11] 罗文慧, 董宝田, 王泽胜. 基于CNN-SVR混合深度学习模型的短时交通流预测[J]. 交通运输系统工程与信息, 2017, 17(5): 68–74. [LUO W H, DONG B T, WANG Z S. Short-term traffic flow prediction based on CNN-SVR hybrid deep learning model[J]. Journal of Transportation Systems Engineering and Information Technology, 2017, 17(5): 68–74.]